

Прогнозирование потребления муниципальных образований

Конкурс СберИндекса · направление «Прогнозирование»

Задача

Прогнозировать потребление в муниципальных образованиях и заранее выявлять точки структурных изменений.

Данные — потребительские безналичные расходы СберИндекса:

муниципальных образований	2190
период	январь 2023 — декабрь 2024
точек на ряд	24
категорий трат	6

Двадцать четыре точки на ряд определяют в этой работе всё.

Главный вывод

 Задача только выглядит как прогноз двух тысяч муниципалитетов

На деле это прогноз **одного числа** и разнос его по территориям.

Измерение. Ошибка делится на промах мимо общего движения страны и разброс между муниципалитетами. Разброс укладывается в **695–849 ₽ по всем 18 сочетаниям модели и фолда** при стандартном отклонении 47. MAE при этом гуляет от 781 до 3 535. Остальное не сдвинула ни одна из шести моделей разложения.

Конструкция. Двухэтапная модель прогнозирует **один** федеральный ряд и разносит долями, не глядя на динамику отдельных рядов — и на фолде с самой короткой историей оказывается лучшей из всех.

Первая находка: ловушка годовой сезонности




Годовая сезонность на 15 точках не идентифицируется — **прогноз уходит в отрицательные значения**. Prophet предупреждает об этом сам.

Один флаг: на полной панели MAE 22 527 ₽ против 1 581 у эталона — в **14 раз** больше, R^2 пул $-9,19$; подгонка дороже.

Уведомление

Эталон конкурса при этом в порядке. Prophet по умолчанию задаёт `yearly_seasonality='auto'` и на истории короче 730 дней сам её не включает, выводя предупреждение; ловушка срабатывает только при ручном включении сезонности. Эталон обходит наивный прогноз на 14,7%, так что планка настоящая.

Архитектура решения



Основной протокол — `configs/full.yaml` (пилот на 300 рядах — `configs/baseline.yaml`);
горизонты — `configs/horizons.yaml`, разладки — `configs/changepoints.yaml`. В коде моделей нет ни горизонта, ни правил разбиения.

Сравнение моделей прогнозирования



Классические модели — **потолок подхода «одна модель на ряд»**; насильная годовая сезонность не показана, чтобы не сжимать шкалу.

Метрики рядом: MAE, MASE, R^2

модель	MAE, ₹	MASE	R^2 пул	R^2 медиана	MAE к Prophet, %
фактор + категории рядами	1 217	0,62	0,978	0,31	+23,0
двухэтапная	1 393	0,75	0,974	−0,40	+11,9
базовая панельная	1 466	0,73	0,970	−0,13	+7,3
эталон конкурса	1 581	0,84	0,961	−0,57	0,0
дообученный Chronos	1 830	0,97	0,957	−0,56	−15,8
наивная	1 852	1,01	0,935	−1,01	−17,2

Среднее R^2 по парам ряд × фолд в таблицы не идёт: на трёх тестовых точках оно вырождено — от −39,0 до −7,3, и лучшей по нему выходит наивная модель, худшая по MAE.

Что дало выигрыш

Не более хитрая модель одного ряда, а информация со стороны.

Глобальная модель обучается на всей панели сразу и предсказывает **отношение к последнему значению**, а не уровень:

- Магадан с 74 тыс. руб. и сельский район с 10 тыс. становятся сопоставимы
- модель учится на форме динамики, а не на масштабе

Это даёт 7,3% над эталоном. Остальное — два внешних источника.

Перенос с длинных рядов: чего не хватает панели

Первый фолд (в таблицах — фолд 0): обучение кончается мартом 2024, прогнозируем апрель-июнь. Признакам нужно шесть точек истории, поэтому целевые месяцы в обучении — только июль-декабрь и январь-март.

Апреля, мая и июня в обучении нет ни разу.

Панельная модель не может знать апрельскую сезонность. Федеральный ряд потребительских расходов — 93 месяца — видел пять апрелей.

Связь измерена: корреляция темпов роста с панелью **0,91**, эластичность **1,23**.

Переносится не всё и не как угодно

конструкция	MAE, ₽	Δ к базовой
общий фактор + категории рядами	1 217	−249 ₽
общий фактор из длинной истории	1 236	−230 ₽
доли категорий как признаки	1 273	−193 ₽
категории как обучающие ряды	1 326	−140 ₽
базовая, без внешних источников	1 466	—
предобучение на отраслевых рядах	1 473	+6 ₽
те же ряды как внешние регрессоры	1 934	+467 ₽

Те же данные. Пять конструкций. Работают две.

Среднее скрывает перемену мест

модель (MAE, ₹)	фолд 0: обучение 15 мес.	фолд 1: обучение 18 мес.	фолд 2: обучение 21 мес.
наивная	805	1 218	3 535
базовая панельная	2 387	1 128	883
общий фактор + категории	1 641	845	1 165

На первом фолде наивную не обходит ни одна панельная, на третьем она же худшая — ни одна модель не берёт все три фолда.

Разложение ошибки первого фолда: модель предсказывает падение на 8,3%, факт — рост на 1,1%; **две трети ошибки — общее смещение**, а не разброс по рядам.

Двухэтапная модель как конструкция

модель (MAE, ₽)	фолд 0: обучение 15 мес.	фолд 1: обучение 18 мес.	фолд 2: обучение 21 мес.	среднее
наивная	805	1 218	3 535	1 852
двухэтапная, сырой агрегат	781	1 587	1 811	1 393
двухэтапная, сглаженный агрегат	2 592	1 218	3 535	2 448

Разброс двухэтапной модели **совпадает с наивной до рубля** — 695, 774 и 824: тождество по построению, обе дают «последнее значение × общий множитель». Разница между ними — ровно общий фактор, и он стоит **460 ₽ из 1 852**.

Сезонно сглаженный агрегат не годится: сглаживание вычищает именно ту сезонность, которую разнос делит между муниципалитетами, — январь и декабрь у сырого агрегата и у самой панели расходятся на десятки процентных пунктов, у сглаженного разница на порядок меньше.

Внутренний бэкtest выбирает на нём [random_walk](#).

Пять горизонтов: от наукаста до года

модель (MAE, ₽)	наукаст (9 фолдов)	3 мес (3)	6 мес (2)	12 мес (1)
наивная	1 611	1 852	2 632	2 691
эталон конкурса	1 550	1 581	2 137	2 722
фактор + категории рядами	839	1 217	1 442	нет примеров
двухэтапная	1 018	1 393	1 749	1 642

Наукаст: 45,9% над эталоном. Известный агрегат за текущий месяц добавляет 21,4 рубля: движение страны на месяц предсказуемо, остаток — разброс.

Год вперёд: у панельных моделей нет обучающих примеров, двухэтапная обходит эталон на 40%. Даже оракул общего движения не разносит точнее 1 356.

Ошибка растёт не с расстоянием, а с календарём. От декабря наивная ошибается на 7 036 в январе и на 1 211 в августе.

Прогноз на 2025 год: первый этап сверен с фактом



Прогноз от последнего месяца панели, декабря 2024: на 1, 3 и 6 мес. — панельная модель с долями категорий, на 12 — двухэтапная; 2 028 рядов в [results/forecast_2025.csv](#).

Федеральный агрегат за 2025 год уже опубликован: первый этап двухэтапной модели ошибся в среднем на 4,1%, «как в декабре» — на 7,0%, «как год назад» — на 12,4%. Прогноз ниже факта все 12 месяцев: первый этап берёт медианный прирост 2019–2024, а 2025-й рос быстрее.

Муниципальный прогноз проверит факт разреза за 2025 год; на истории на год точнее разнос опубликованного агрегата ([two_stage_known](#)), на месяц — панельная модель.

Короче история — ценнее перенос

Выигрыш переноса к базовой модели, ₴ (минус = помогает):

	12 мес	15 мес	18 мес	21 мес
общий фактор + категории	−7 590	−746	−283	+281
базовая модель, MAE, ₴	9 213	2 387	1 128	883

Ранговая корреляция выигрыша с длиной обучения — 0,96.

Девять дополнительных месяцев улучшают модель в 10,4 раза — наивную модель тот же срок не улучшает вовсе: её ошибка зависит от того, какие месяцы попали в тест, а не от длины истории.

Предупреждение

Прогнозировать предстоит с 24 месяцами обучения — за правым краем развёртки. Для практики берём не лучшую по среднему модель, а лучшую на самом длинном обучении.

Почему регрессоры проваливаются

Федеральный ряд в месяце t **одинаков для всех 2028 муниципалитетов**: значений в обучении фолда ровно столько, сколько там моментов.

- **9 различных значений** на всё обучение первого фолда
- треть признаков — **вне диапазона обучения**, и дерево там отдаёт константу

Это метка месяца, а не регрессор.

Общий фактор работает иначе: длинный ряд отвечает на вопрос, на который короткий не может — какова сезонная форма месяца, которого в обучении не было.


Обнаружение разладок: решает преобразование

метод	обнаружено, %	задержка, медиана, мес.	ложных, %	J Юдена	сырые: ложных, %	сырые: J
PELT	13,9	3	0,0	+13,9	66,7	−31,3
BinSeg	13,9	3	0,0	+13,9	66,7	−31,7
BottomUp	11,9	3	0,0	+11,9	53,3	−25,3
ядровой	4,7	3	0,0	+4,7	66,7	−45,8
Window	3,8	3	0,0	+3,8	73,3	−42,5
CUSUM	20,1	1	58,3	−38,2	100,0	−81,1

Штраф 5 — по стенду, до реальных данных, край сетки: лучший мог лежать за ним. Зачёт — не позже 3 мес. после врезки, при молчащем нетронутом близнеце. Лучший J — у PELT и BinSeg. **Но у методов со штрафом на темпах роста 64,4–79,7% засчитанного — сигналы в декабре; у PELT без них 4,6%.**

На сырых рядах детекторы ловят сезонность и структуру рядов, а не изломы.

Интерпретация на реальных данных



- **Штраф 5, выбран по стенду:** порог 50% не перейдён ни разу, наибольшая доля — 0,6% (октябрь 2023); октябрь 2023 — первый по доле месяц, но это 12 МО из 2 028; фон нулевой.
- **Штраф 1:** октябрь 2024 — порог в декабре 2024 (79,5% против 2,4 и 2,1% в октябре и ноябре — сигнал в самом декабре), задержка 2 мес.; октябрь 2023 и январь 2024 — нет (46,7 и 41,4%); сентябрь 2023 выше всех трёх событий — эффект старта; фон 2,1% (43 МО).
- **Задним числом, по полному ряду** (штраф 1): октябрь 2023 — 50,5%, январь 2024 — 63,7%, октябрь 2024 — 85,8%; в остальные месяцы не выше 12,1%.

ранговый вид	штраф 5	штраф 1
октябрь 2023	1 из 16 (0,6%)	5 из 16 (14,4%)
январь 2024	10,5 из 16 (0%)	14 из 16 (0,2%)
октябрь 2024	10,5 из 16 (0%)	8 из 16 (2,4%)

Чего мы не утверждаем

Трёх событий недостаточно для вывода о причинности: связь с денежной политикой — совпадение и гипотеза.

Октябрь 2023 и январь 2024 по полному ряду — не два шока: у 1 024 из 1 025 рядов с изломом в октябре 2023 есть излом и в январе 2024: это начало и конец одного отрезка.

Январь неотделим от сезонности: ряд начинается в январе 2023, и детектируемый январь у нас ровно один.

Показатель — оценка среднечеловеческих расходов, методология муниципального уровня не опубликована. Мы прогнозируем **опубликованный ряд**, а интерпретируем только относительные величины.

Что не сработало: модели

Фундаментальные модели без дообучения. На горизонте 3 мес. Chronos-Bolt small проигрывает наивной на 41%, Moirai на 22%, TimesFM 2.5 на 14% — в среднем; на третьем фолде Moirai, TimesFM 2.5 и Chronos-Bolt base наивную обходят. **Три** разных семейства сходятся, значит дело не в архитектуре. Там же дообучение Chronos снимает 30% ошибки (2 620 → 1 830) и доводит его лишь до уровня наивной (на 1,2% лучше): эталону уступает 15,8%, панельной модели — в 1,5 раза. На наукасте — лишь 1,6% (2 026 → 1 994), и он на 23,8% хуже наивной; на 6 и 12 мес. дообучение пропускается или отказывается. Повтор с тем же сидом расходится на третьем фолде: 2 326 (снимок локального прогона, в репозиторий не входит) против 2 337. Больше параметров в среднем хуже: дообученный base даёт 2 004 против 1 830 у small.

Ансамбль (пилот, 300 рядов). Смесь с весом по тесту давала +9,6%. При честном подборе веса — −40%. Оптимальный вес нестабилен между фолдами.

⚠ Важное уведомление

Все эти результаты измерены и приведены как есть. На 24 точках почти любой метод покажет улучшение, если подбирать параметры по тем же данным, на которых меряешь.

Что не сработало: новости и длинные ряды

Новости, три независимые конструкции. 589 тыс. заголовков, 18 регионов. Признаки в модели на наукасте: ошибка ниже на 21,5 ₪ на 396 покрытых рядах, но интервал по фолдам $[-78; +35]$ накрывает ноль, на всех рядах не лучше базовой. Событийный анализ на изломах, 42 проверки, и та же региональная проверка корреляцией, 12: ни одной значимой. **Национальный уровень против федерального агрегата — 48 гипотез, порог объявлен заранее, не прошла ни одна.**

Заголовки не виноваты: по выборке в 20 тыс. статей с телами тело добирает медианно 1,2% из непопавших, а связь с целью меняется вдвое слабее шума выборки.

Длинные ряды в двух конструкциях из четырёх. Как внешние регрессоры — хуже на треть. Предобучение на 56 отраслевых рядах — интервал $[-16; +29]$, ноль. Эластичность по регионам устойчива (корреляция половин периода 0,77), но усиливает не только сигнал, но и ошибку прогноза фактора.

Выводы

- **Главный вывод:** задача — прогноз одного числа и разнос его по территориям.
- **Информация со стороны:** 23,0% к эталону (MAE, 3 мес.) против 7,3% у панели без переноса — на 2 фолдах из 3, на первом эталон точнее.
- **Горизонты:** наукаст — 45,9% к эталону; на год — двухэтапная, 39% и 40% к наивной и эталону (один фолд).
- **Агрегат на факте 2025 года:** ошибка первого этапа 3,8–4,5% против 7,0–17,1% у простых правил.
- **Закон переноса:** корреляция выигрыша с длиной обучения 0,96; базовая модель при 21 мес. точнее, чем при 12, в 10,4 раза.
- **Ловушка:** насильная годовая сезонность — MAE 22 527 ₽ вместо 1 581 ₽ у Prophet по умолчанию.
- **Фундаментальные:** без дообучения хуже наивной, дообученный Chronos — 1 830 против 1 852 ₽ у неё.
- **Новости:** на наукасте ошибка ниже на 21,5 ₽ на 396 рядах, но интервал по фолдам накрывает ноль.
- **Изломы:** решает преобразование — ложных 53,3–73,3% на сырых рядах, 0% на темпах роста; уровень скромный, раннего предупреждения нет.

Что из этого следует

Осторожно с определённой. Ни одна модель не выигрывает у наивной на всех трёх фолдах. По фолдам интервалы накрывают ноль у всех конструкций. Приводим обе оценки и не выбираем удобную.

Главный практический вывод. Три дополнительных месяца истории меняют качество прогноза сильнее, чем переход от наивной модели к градиентному бустингу: на фолдах с обучением 18 и 21 точка MAE базовой панельной модели в среднем 1 006, на фолде с 15 точками — 2 387.

Для задач такого рода длина ряда важнее выбора метода.